

제목을 입력하세요

(Put English Title Here)

요 약

이곳에 한글 요약문을 작성하여 주십시오. (스타일:요약본문)

ABSTRACT

Please put the abstract of paper here.(스타일:요약본문)

키워드 : 한글 키워드

Keywords : 영문 키워드 (스타일:Keywords내용)

I. 서론

여기에 서론을 입력하세요. (스타일:본문)

여기에 내용을 입력하세요. (스타일:본문)

여기에 내용을 입력하세요. (스타일:본문)

여기에 내용을 입력하세요. (스타일:본문)

II. 본론 (스타일:각 장 제목)




Fig. 6. 여기에 그림 제목을 입력하세요 (마침표삭제)
그림 6.Please put the title of figure here.

(그림 안의 내용을 영문으로 작성하시기 바랍니다.)




그림 7. 여기에 그림 제목을 입력하세요 (마침표삭제)
Fig. 7. Please put the title of figure here.

(그림 안의 내용을 영문으로 작성하시기 바랍니다.)

1. 각 절 제목 (스타일:각 절 제목)

여기에 내용을 입력하세요. (스타일:본문)

1.1. 각 항 제목 (스타일:각 항 제목)

여기에 내용을 입력하세요. (스타일:본문)

1.1.1 각 항 제목 (스타일:각 항 제목)

수식 맨 끝에 번호를 기입하세요.

(1)

(표 안의 내용을 영문으로 작성하시기 바랍니다.)

표 1. 여기에 그림 제목을 입력하세요(마침표삭제)
Table 1. Please put the title of table here.

III. 실험

3.1 데이터셋

LWM 파운데이션 모델의 성능을 측정하기 위해서 DeepMIMOv3 에서의 Dynamic Scenerio 데이터를 가지고 실험을 진행하였다. 해당 데이터셋은 총 999개의 시나리오로 구성되어 있으며, 각 장면에는 채널 임펄스 응답(Channel Impulse Response, CIR), 전파 손실(Path Loss, PL), 입사·출사 각도(DoA/DoD), 송·수신기 위치(RX/TX) 등 다양한 채널 특성이 포함되어 있다.

또한, 본 실험에서 OFDM(Orthogonal Frequency Division Multiplexing) 파라미터를 적용하였으며, 대역폭(Bandwidth)를 50MHz, 총 서브캐리어(Subcarriers)를 512개로 설정하였고, 이 중 0번부터 63번까지의 64개 서브캐리어를 채널 예측에 활용하였다.

3.2. 데이터 전처리

본 연구에서는 DeepMIMOv3 Dynamic Scenerio 데이터셋으로부터 모델 입력 및 예측 타깃을 생성하기 위해, 다음과 같은 일련의 전처리 과정을 수행하였다. 우선, 각 시점 t 에서 기지국-사용자 간 채널 응답 $h \in C^{A \times S}$ 중 특정 사용자 u 및 서브캐리어 s 에 해당하는 복소수 벡터 $h_u \in C^A$ 를 추출하였다. 이어서 실수부 $\Re(h_u)$ 와 허수부 $\Im(h_u)$ 를 상하로 결합하여

$$v = \begin{bmatrix} \Re(h_u) \\ \Im(h_u) \end{bmatrix} \in \mathbb{R}^{2A}$$

형태의 실수 형태로 변환하였다.

이 변환된 벡터 v 는 채널 강도에 따라 값의 분포가 크게 달라질 수 있으므로, 평균 제곱 에너지를 1로 맞추는 파워 정규화(power normalization)를 적용하였다. 정규화는

$$v = \frac{v}{\sqrt{\frac{1}{2A} \sum_{i=1}^{2A} v_i^2 + \epsilon}}, \epsilon = 10^{-9}$$

로 수행했으며, 여기서 ϵ 는 분모 0 방지를 위한 작은 상수이다.

정규화된 벡터 $\tilde{v}$ 에 대해서 입력(X)과 예측 타깃(Y) 각각의 별도의 MinMaxScaler를 fit하여 $[0, 1]$ 구간으로 선형 변환하였다. 즉, 과거 seq_len 스텝의 벡터

$$\{\tilde{v}_{t-\text{seq_len}}, \dots, \tilde{v}_{t-1}\}$$

를 입력하여 $X \in \mathbb{R}^{\text{seq_len} \times 2A}$ 로, 시점 t 의 벡터 $\tilde{v}_t$ 를 예측 타깃 $Y \in \mathbb{R}^{2A}$ 로 설정하였다. 또한, 각 장면에 따른 분류, 유저에 따른 분류, 서브캐리어에 따른 분류를 subfileter 파라미터를 사용하여 각 옵션에 맞는 인덱스만을 선택적으로 포함하도록 하였으며, 이 필터링은 벡터 생성 단계에서 적용된다.

3.3 학습/검증 분할

본 연구에서는 입력 시퀀스 길이($\text{seq_len} = 14$)와 배치 크기($\text{batch_size} = 256$)를 고정한 후, 모델의 일반화 성능을 다각도로 평가하기 위해 세가지 분할 전략을 적용하였다. 각 전략은 3:1(75%:25%) 비율로 학습용 및 검증용 데이터를 분리하며, 재현성을 확보하였다.

옵션 1: 장면(Scene) 단위 분할

총 999개 시나리오 중 앞 시나리오 44개를 추출한 뒤, 처음 26장면을 학습용으로 뒤 18개를 검증용으로 분할하였다.

과거 14장면을 관찰하고 다음 1장면을 예측하는 방식($\text{seq_len} = 14$)를 적용하면,

학습 세트의 유효 시점 수: $26 - 14 = 12$

검증 세트의 유효 시점 수: $18 - 14 = 4$

따라서, 학습 세트에서 생성되는 입력-타깃 쌍의 총 개수는

$$(26 - 14) \times U \times S = 12US$$

검증 세트에서는

$$(18 - 14) \times U \times S = 4US$$

이다. 본 실험에서는 사용자 $U = 737$, 서브캐리어 수 $S = 64$ 를 사용하였으므로, 학습 샘플 수는

$$12 \times 737 \times 64 = 566,016$$

검증 샘플 수는

$$4 \times 737 \times 64 = 188,672$$

로 계산된다.

표 1. 장면 단위 분할 파라미터

Table 1. Scene-level Split Parameters

Parameter	Value
Total scenes	999
Scenes used	44
Train scene	26
Validation scene	18
Sequence length(seq_len)	14
Windows per scene(N-seq_len)	12(train), 4(val)
Users (U)	737
Subcarrier (S)	64
Train samples	566,016
Validation samples	188,672

옵션 2: 사용자(User) 단위 분할

본 실험에서는 앞서 선택한 30개 장면을 대상으로 전체 사용자 737명을 학습·검증 세트로 3:1(75%:25%) 비율로 분할하였다. 먼저 각 장면의 전체 이용자 수 737만큼 인덱스 $\{0, \dots, 736\}$ 을 생성하고, 무작위로 섞은 뒤 상위 75%에 해당하는 545명을 학습용 사용자 집합(train_users)으로, 하위 25%에 해당하는 182명을 검증용 사용자 집합(val_users)으로 지정하였다.

입력 시퀀스 길이 $\text{seq_len} = 14$ 를 적용하면 각 장면 당 유효 시점 수는

$$30 - 14 = 16$$

이며, 모든 서브캐리어(S)에 대해 사용자별로 샘플을 생성하였으므로 총 샘플 수는

$$N_{\text{train}} = (30 - 14) \times |\text{train_users}| \times S$$

$$N_{\text{val}} = (30 - 14) \times |\text{val_users}| \times S$$

이다.

본 실험에서는 학습 이용자가 545명이므로

$$N_{train} = 16 \times 545 \times 64 = 558,080$$

$$N_{val} = 16 \times 182 \times 64 = 186,368$$

로 계산이 된다.

표 2. 사용자 단위 분할 파라미터
Table 2. User-level Split Parameters

Parameter	Value
Total scenes	999
Scenes used	30
Users (U)	737
Train users	545
Validation users	182
Sequence length(seq_len)	14
Windows per scene(N-seq_len)	16
Subcarrier (S)	64
Train samples	558,080
Validation samples	186,368

옵션 3: 서브캐리어(Subcarrier) 단위 분할

본 실험에서는 앞서 선택한 30개 장면을 대상으로 전체 서브캐리어 64개를 학습·검증 세트로 3:1(75%:25%) 비율로 분할하였다. 먼저 0번부터 63번까지의 서브캐리어 인덱스{0,...,63}를 생성한 뒤, 무작위로 섞어 상위 75%에 해당하는 48개를 학습용 서브캐리어 집합($train_{sc}$)으로, 하위 25%에 해당하는 16개를 검증용 서브캐리어 집합(val_{sc})으로 지정하였다.

입력 시퀀스 길이(seq_len)를 14로 설정하면, 각 장면당 유효 시점 수는

$$30 - 14 = 16$$

이다.

따라서 총 샘플 수는 다음의 일반식에 따라 계산된다.

$$N_{train} = (30 - 14) \times |train_{sc}| \times U$$

$$N_{val} = (30 - 14) \times |val_{sc}| \times U$$

본 실험에서는 사용자 수 $U = 737$ 이므로,

$$N_{train} = 16 \times 48 \times 737 = 566,016$$

$$N_{val} = 16 \times 16 \times 737 = 188,672$$

로 계산된다.

표 3. 서브캐리어 단위 분할 파라미터
Table 3. Subcarrier-level Split Parameters

Parameter	Value
Total scenes	999
Scenes used	30
Subcarrier (S)	64
Train subcarrier	48
Validation subcarrier	16
Sequence length(seq_len)	14
Windows per scene(N-seq_len)	16

User (U)	737
Train samples	566,016
Validation samples	188,672

3.3 모델 아키텍처

본 연구에서 비교한 모든 모델은 크게 세 개의 구성 요소로 이루어진다: (1) 입력 투영층(input projection), (2) 시퀀스 인코더(backbone), (3) 다운스트림 태스크를 위한 완전연결 헤드(FC head).

입력 투영층 (Input Projection)

원천 채널 정보는 하나의 타임스텝 당 A 개의 안테나 복소 응답($real + imag$ 결합 시 $2A$ 차원)으로 표현된다. 이를 모든 모델이 공통으로 처리하기 쉽도록 고정된 차원($patchLength = 16$)으로 선형 사영(linear projection)한다.

$$x \in \mathbb{R}^{B \times T \times 2A} \xrightarrow{\text{Linear}(2A \rightarrow 16)} x_{proj} = x W_{proj} + b_{proj}$$

$$, W_{proj} \in \mathbb{R}^{2A \times 16}$$

여기서 B 는 배치 크기, T 는 시퀀스 길이(seq_len = 14)이다.

시퀀스 인코더(Backbone)

- LWMWithHead

사전학습된 LWM(Transformer encoder) 파운데이션 모델을 backbone으로 사용하며, 파라미터 조정 방식에 따라 세 가지 변형을 실험하였다:

1. Freeze Backbone(LWM_freeze_backbone) :

backbone 파라미터 고정, FC head만 학습

2. Pre-trained

Fine-tuning(LWM_pretrained_Fine_tune) :사전학습

가중치로 초기화 후 backbone+head 모두 미세조정

3. Full Fine_tuning(LWM_Fine_tune): 랜덤 초기화된

백본·헤드를 함께 학습

세 변형 모두 $N_{enc} = 12$ 개의 Transformer encoder 블록을 사용하며, 인코더 출력의 CLS 토큰 벡터

$$z_{CLS} = enc_out[:, 0, :] \in \mathbb{R}^{64}$$

를 FC head로 전달한다.

-RNN 계열(GRUWithHead, RNNWithHead, LSTMWithHead)

세 가지 깊이 및 은닉 차원 버전으로 실험하였다.

표 4. RNN 계열 모델별 구조 및 하이퍼파라미터
Table 4. RNN-based Models: Architecture and Hyperparameter Settings.

모델	셀 종류	레이어 수 N	은닉차원 d_{hid}
DL_1	GRU/RNN/ LSTM	1	30
DL_2	GRU/RNN/ LSTM	2	15
DL_3	GRU/RNN/ LSTM	3	10

-TransformerWithHead

자체 구현한 Transformer encoder-decoder 구조를 백본으로 사용하였다.

1. 인코더

IV. 결 론

여기에 내용을 입력하세요.

References

- [1] M. Armstrong, J. Wright, *Mobile call termination in the UK*, UCL, Sep. 2007. (<https://doi.org/~>)
- [2] U. Berger, "Access charges in the presence of call externalities," *Journal of Economic Analysis & Policy*, 3(1), Article 21, 2004. (<https://doi.org/~>)
- [3] U. Berger, "Bill-and-keep vs. cost-based access pricing revisited," *Economics Letters*, 86(1), pp.107-112, 2005. (<https://doi.org/~>)
- [4] D. Birke, G. Swann, "Network effects and the choice of mobile phone operator," *Journal of Evolutionary Economics*, 16(1-2), pp. 65-84, 2006. (<https://doi.org/~>)

<<참고문헌(영문으로 작성)작성요령>>

1. 작성 방법

- (1) 참고문헌은 본문에 인용한 것만을 반드시 영문으로 기재해야 하며, 기재 방법은 아래와 같은 순서대로 하고, 잡지명과 도서명에는 기울임 효과를 준다.
- (2) 참고문헌 목록에는 적어도 국내에서 발표된 논문 1편(국내 학술대회 및 국내학회 발행 논문지 포함) 이상이 포함되어야 한다.
- (3) 논문 제목의 첫 글자의 처음 알파벳은 대문자로 표시한다.(참고문헌 작성 예 참고)
- (4) 본문에서 인용한 참고문헌 번호는 인용문 우측 상단의

[]안에 기입한다.

예) [1]. 윗첨자

2. 참고문헌 작성 예:

Ex1) 논문집의 경우(저자명, "제목," 잡지명, 권, 호, 페이지, 월, 연도.) (<https://doi.org/~>)

[1] S. K. Oh and E. B. Goldsmith, "The better manuscript preparation for speedy publication," *J. Commun. Networks (JCN)*, vol. 13, no. 6, pp. 10-16, Dec. 2011. (<https://doi.org/~>)

Ex2) 단행본의 경우(저자명, 도서명, 출판사명, (페이지), 연도.) (<https://doi.org/~>)

[2] J. K. White, *Communications and Networks*, 2nd Ed., KICS Press, 2010. (<https://doi.org/~>)

Ex3) 학술대회 논문집의 경우(저자명, "제목," 학술대회논문집명, 페이지, 개최도시, 국가, 월, 연도.) (<https://doi.org/~>)

[3] K. B. Lee, S. Smith, and K. K. Silver, "Conference proceeding paper," in *Proc. KICS Int. Conf. Commun. 2010 (KICS ICC 2010)*, pp. 201-205, Jeju Island, Korea, June 2010. (<https://doi.org/~>)

Ex4)사이버 문서의 경우(저자명, 제목(연도), 접속일시(월, 일, 연도), URL.) (<https://doi.org/~>)

[4] J. Park, *A Guide to Journal Publication*(2011), Retrieved Aug., 30, 2012, from <http://www.kics.or.kr>. (<https://doi.org/~>)

<<폰트문제>>

본 한글스타일 파일에서는 기본폰트를 사용하므로 논문지 실리는 게재논문의 폰트와는 다를 수 있다.